

Predicción de transiciones de privación básica en hogares colombianos mediante modelos de ensamble: evidencia longitudinal con la ELCA (2010-2016)

Talia Linares · Camilo Rendón · Nicolás Cubillos · Alejandro Velandia

1. Resumen

El estudio realizado predice transiciones de privación básica en hogares colombianos utilizando datos longitudinales de la ELCA (2010-2016). Se realizó la construcción del Índice de Privaciones Básicas del Hogar (IPBH) en tres dimensiones: educación, salud y vivienda y se clasifican 16.957 hogares en cuatro estados: estable, vulnerable, movilidad ascendente y crónico. Se incorporan 14 variables nuevas sobre choques climáticos, resiliencia financiera y subsidios. Tras comparar cuatro modelos con GridSearchCV y validación cruzada estratificada ($k=5$), el XGBoost obtiene el mejor desempeño (AUC-ROC: 0.9245). El umbral de decisión se ajusta para maximizar la detección de hogares vulnerables, mejorando el Recall de 12.9% a 74.4%. El análisis SHAP sobre el modelo campeón confirma que la Riqueza (PCA) es el predictor dominante, con efectos diferenciados por clase. El hallazgo central es que el 77.5% de los hogares no cambia de estado entre periodos, evidenciando trampas de privación estructurales que el Estado puede anticipar y prevenir mediante focalización preventiva, acceso a crédito rural e inversión en infraestructura habitacional.

2. Introducción

En Colombia, la pobreza multidimensional no es un evento circunstancial: es una trampa. Según el DANE (2024), más de seis millones de personas presentan privaciones simultáneas en educación, salud y vivienda. Pero la cifra más reveladora no es cuántos son pobres hoy, sino cuántos lo siguen siendo mañana. Los modelos estáticos de medición del IPM responden quiénes están en privación. Este proyecto responde una pregunta diferente y más urgente para la política pública: ¿quiénes van a caer, y cómo podemos saberlo antes de que pase?

La Encuesta Longitudinal Colombiana (ELCA) ofrece una oportunidad única para responder esta pregunta: al seguir los mismos hogares en 2010, 2013 y 2016, permite observar trayectorias individuales de movilidad y privación imposibles de capturar con datos de corte transversal. Combinada con técnicas de Machine Learning, esta fuente permite construir un sistema de alerta temprana que identifique el perfil de los hogares en riesgo antes de que colapsen.

La relevancia económica es concreta. El gasto social del Estado colombiano a través de programas como Familias en Acción y Red Juntos supera los 8 billones de pesos anuales (DNP, 2022). Sin embargo, la evidencia muestra que el 64.5% de los hogares crónicos los más privados ya reciben subsidios y siguen en privación. El problema no es la cobertura: es la oportunidad. Los programas llegan después de que el hogar cayó. Un modelo predictivo que permita anticipar la caída puede reorientar el gasto hacia la prevención, con un impacto potencialmente mucho mayor por peso invertido.

3. Pregunta de investigación e hipótesis

Pregunta de investigación: ¿Qué variables del hogar incluyendo choques externos, resiliencia financiera y acceso a subsidios del Estado permiten predecir con mayor precisión la transición entre estados de privación básica en hogares colombianos observados longitudinalmente entre 2010 y 2016?

Hipótesis: La acumulación de activos físicos y financieros es el principal factor protector frente a la privación. Los hogares con mayor patrimonio pueden absorber choques sin caer, mientras que quienes no tienen activos ni acceso a crédito son estructuralmente vulnerables. Esperamos que la riqueza del hogar sea la variable más predictiva, que los choques climáticos sean el principal desencadenante de las transiciones negativas, y que los estados persistentes estable y crónico sean más predecibles que las transiciones dinámicas, cuya determinación depende de eventos imprevistos no observables en el periodo inicial.

4. Análisis Exploratorio de Datos

4.1 Las trampas de privación: el 77.5% no cambia

El primer hallazgo del EDA es el más contundente. Clasificados los hogares según su condición de privación en pares de periodos, el 77.5% permanece en el mismo estado: 48.2% estables y 29.3% crónicos. Solo el 22.5% experimenta una transición, el 12% asciende y el 10.5% cae. Esto no es movilidad social baja: es inmovilidad estructural. Un hogar que entra en privación tiene más probabilidades de permanecer en ella que de salir.




Figura 1. Distribución de transiciones de privación en hogares ELCA (2010-2016). Fuente: elaboración propia.

4.2 El Índice de Privaciones Básicas del Hogar (IPBH)

Para medir quién está en privación se construyó el IPBH con tres dimensiones disponibles en la ELCA. La privación en salud se definió como la ausencia simultánea de SISBEN y de afiliación a EPS, capturando únicamente a hogares sin ningún tipo de cobertura. Esta definición es más precisa que usar solo el SISBEN como proxy, ya que en Colombia la cobertura en salud es aproximadamente del 95% quienes no tienen EPS están en el SISBEN y viceversa.

El 47.8% de los hogares tiene alguna privación. La más extendida es vivienda y servicios (41.3%), seguida por salud y educación (10.2%). La brecha por estrato es evidente pues: en estrato 1, el 57% es crónico; en estrato 4, apenas el 2%.




Figura 2. Incidencia del IPBH por dimensión y distribución de intensidad. Fuente: elaboración propia.

4.3 El patrimonio como escudo: activos y riqueza

La correlación entre Riqueza (PCA) y transición es de -0.63, la más alta de todas las variables. Los hogares estables tienen un índice de activos promedio de 14.9, comparado con 9.0 de los crónicos. Esta brecha no es sorprendente teóricamente, los activos son el colchón que permite absorber un choque sin colapsar pero su magnitud sí lo es. El Índice de activos e Riqueza (PCA) miden dimensiones complementarias: el primero suma bienes físicos contables; el segundo captura una dimensión más amplia del bienestar patrimonial mediante análisis de componentes principales. Ambos permanecen en el modelo porque su correlación, aunque alta, no es perfecta y cada uno aporta información independiente.




Figura 3. Distribución del índice de activos y riqueza (PCA) por tipo de transición. Fuente: elaboración propia.

4.4 La paradoja de los subsidios y la brecha rural

Las 14 variables incorporadas al modelo revelan dos hallazgos de alto valor para política pública. Primero, la brecha de resiliencia: los hogares rurales tienen un índice de resiliencia financiera de 0.24, casi tres veces menor que el urbano (0.63). Solo el 10.9% tiene acceso a crédito formal. Sin instrumentos de protección financiera, cualquier choque una inundación, una enfermedad, una caída del precio agrícola puede ser devastador.

Segundo, la paradoja de los subsidios: los hogares crónicos reciben más subsidios que los estables (64.5% versus 32%). La focalización del Estado llega a quien debe llegar. Pero no es suficiente para sacarlos, porque la privación principal es habitacional el 41.3% tiene carencias en vivienda y una transferencia monetaria no resuelve que no hay acueducto o que el techo tiene goteras.




Figura 4. Resiliencia financiera y cobertura de subsidios por tipo de transición. Fuente: elaboración propia.

Estos hallazgos tienen implicaciones directas para el diseño de política. Si los programas de subsidios están llegando correctamente a los crónicos pero no los sacan de la privación, el problema no es de cobertura sino de tipo de intervención. Una transferencia monetaria no resuelve la ausencia de acueducto, y el acceso al SISBEN no reemplaza la capacidad de ahorrar o acceder a crédito cuando llega un choque. El modelo captura estas interacciones y las cuantifica.

5. Metodología

El problema se define como una tarea de clasificación supervisada multiclase: predecir el estado de transición del hogar (0=Estable, 1=Vulnerable, 2=Movilidad ascendente, 3=Crónico) a partir de sus condiciones en el periodo T. Se eligieron cuatro modelos con distintas capacidades para capturar relaciones no lineales y evaluar la robustez de los resultados.

División de datos. 80% para entrenamiento y 20% para prueba con estratificación por clase (stratify=y) para garantizar que la proporción de cada clase, especialmente Vulnerable (10.5%), se

preserve en ambos conjuntos. El EDA se realizó exclusivamente sobre los datos de entrenamiento para evitar fuga de información.

Preprocesamiento. KNNImputer (k=5) para imputación y StandardScaler para estandarización, ambos ajustados únicamente sobre el entrenamiento (fit_transform en train, transform en test). El modelo usa 26 variables: 12 originales de la ELCA y 14 nuevas construidas sobre choques, resiliencia, subsidios y activos productivos.

Selección de modelos. Se comparó Regresión Logística (baseline interpretable), Random Forest (ensamble por promedios), Gradient Boosting (ensamble secuencial) y XGBoost (boosting regularizado). La elección de métrica fue AUC-ROC one-vs-rest, no Accuracy, porque con Vulnerable en solo el 10.5% de los hogares, un modelo que prediga siempre Estable tendría 48% de Accuracy sin aprender absolutamente nada.

Optimización. GridSearchCV con StratifiedKFold (k=5) para encontrar los mejores hiperparámetros de cada modelo simultáneamente.

Ajuste de umbral. El umbral por defecto (0.5) se optimizó usando la curva Precision-Recall, maximizando el F1-Score de la clase Vulnerable. El umbral óptimo resultó 0.19, con justificación económica: el costo de apoyar un hogar que no iba a caer (falso positivo) es mucho menor que el costo de no intervenir en uno que sí cae en privación crónica (falso negativo).

Análisis SHAP. Se utilizó SHAP (SHapley Additive exPlanations) con TreeExplainer sobre el XGBoost campeón para medir la contribución de cada variable a la predicción de cada hogar individual, mostrando dirección y magnitud del efecto.

6. Resultados e interpretación económica

6.1 Comparación de modelos

Modelo	AUC-ROC (CV k=5)	AUC-ROC (Test)	Mejores hiperparámetros
Regresión Logística	0.8983	0.8962	C = 10
Random Forest	0.9146	0.9164	n_estimators=200, max_depth=10
Gradient Boosting	0.9209	0.9233	n_estimators=100, lr=0.05, depth=5
XGBoost ★	0.9223	0.9245	n_estimators=200, lr=0.1, depth=3

Tabla 1. Comparación de modelos por AUC-ROC. ★ Modelo campeón. Fuente: elaboración propia.

El XGBoost lidera en ambas métricas con una diferencia mínima entre CV y test (0.0022), confirmando que no hay sobreajuste. Todos los modelos superan ampliamente el umbral de clasificación aleatoria (AUC = 0.5), validando que las 26 variables tienen poder discriminante real.




Figura 5. AUC-ROC por modelo en validación cruzada. Fuente: elaboración propia.

6.2 El valor del ajuste de umbral

Con umbral por defecto (0.5), el modelo detecta solo el 12.9% de los hogares vulnerables reales dejando pasar el 87%. Con umbral ajustado (0.19), el Recall de Vulnerable sube a 74.4% y el F1 pasa de 0.212 a 0.489. El tradeoff es que Estable baja de 97.8% a 71.5%, consecuencia esperada al bajar el umbral: el modelo ahora clasifica como Vulnerable a 460 hogares que en realidad son estables. Para política pública preventiva, ese tradeoff es racional.




Figura 6. Curva Precision-Recall y F1 vs umbral para la clase Vulnerable. Fuente: elaboración propia.

6.3 Interpretación económica de los resultados




Figura 7. Matrices de confusión con umbral 0.5 (antes) y umbral óptimo 0.19 (después). Fuente: elaboración propia.

Los resultados del modelo con umbral ajustado revelan un patrón económicamente significativo: el modelo predice excelentemente los estados persistentes (Estable: 71.5%, Crónico: 87.7%) pero tiene limitaciones con las transiciones dinámicas (Movilidad ascendente: 28.4%). Esto no es un error técnico, es un hallazgo económico. Los estados persistentes se predicen bien porque sus determinantes son estructurales y están en los datos. Las transiciones dependen de eventos imprevistos en T+1 una inundación, una pérdida de empleo, una oportunidad de capacitación que no están en los datos del periodo T.

6.4 Análisis SHAP: más allá de la importancia global

Análisis SHAP — XGBoost (top 10 variables por clase)




Figura 8. Análisis SHAP por clase de transición — XGBoost (top 10 variables). Fuente: elaboración propia.

El análisis SHAP confirma y enriquece los hallazgos del EDA. Para la clase Crónico, valores bajos de Riqueza (PCA) generan valores SHAP positivos altos: los hogares pobres en patrimonio tienen mayor probabilidad de privación persistente. Para la clase Vulnerable, el choque climático y la baja resiliencia muestran valores SHAP positivos significativos, confirmando que la exposición a desastres combinada con escasos mecanismos de respuesta es el perfil de mayor riesgo de caída. Esto traduce las matemáticas en política: un hogar rural, sin crédito formal, con choque climático reciente y bajo patrimonio concentra múltiples factores de riesgo que el Estado puede identificar preventivamente.




Figura 9. SHAP Values para la clase Crónico (top 15 variables). Fuente: elaboración propia.

7. Conclusiones

7.1 Hallazgos principales

Este proyecto demuestra que la privación básica en Colombia no es impredecible. El XGBoost con umbral ajustado (0.19) obtiene AUC-ROC de 0.9245 y detecta el 74.4% de los hogares vulnerables antes de que caigan. El hallazgo económico central es que el 77.5% de los hogares no cambia de estado, confirmando la existencia de trampas de privación estructurales. El SHAP confirma que la Riqueza (PCA) es el predictor dominante con efectos diferenciados por clase, y que los choques climáticos combinados con baja resiliencia definen el perfil de mayor riesgo.

7.2 Recomendaciones accionables

1. **Focalizar preventivamente.** Familias en Acción y Red Juntos deben llegar antes de que el hogar caiga. El modelo identifica el perfil de riesgo: bajo patrimonio, zona rural, alta exposición a choques climáticos. Con los datos del SISBEN IV y registros administrativos, el DNP podría implementar un sistema de alerta temprana operativo.
2. **Democratizar el crédito formal rural.** El 89% de los hogares rurales no tiene acceso a crédito formal. Sin instrumentos de protección financiera, cualquier choque puede desencadenar privación crónica. La banca de proximidad, los fondos de garantía y los microseguros agropecuarios son intervenciones directas sobre la brecha de resiliencia.
3. **Invertir en infraestructura habitacional.** La privación en vivienda y servicios (41.3%) es la más extendida y no se resuelve con transferencias monetarias. La cobertura de acueducto, alcantarillado y materiales de construcción dignos requiere inversión en infraestructura básica que ataque directamente el componente más prevalente del IPBH.

7.3 Limitaciones y mejoras futuras

El IPBH no captura las dimensiones de niñez y trabajo del IPM oficial por limitaciones de la ELCA. La clase Movilidad Ascendente permanece en 28.4% de Recall porque sus determinantes acceso a mercados laborales, precios agrícolas, capacitación no están disponibles en el periodo T. Como mejoras se recomienda incorporar jefatura femenina, ampliar el análisis a la ronda 2021 para capturar el impacto de la pandemia, y explorar modelos de supervivencia que capturen la duración en cada estado de privación, que tienen mayor valor para la toma de decisiones de política pública.

8. Referencias

- Alkire, S., & Foster, J. (2011). Counting and multidimensional poverty measurement. *Journal of Public Economics*, 95(7-8), 476-487. <https://doi.org/10.1016/j.jpubeco.2010.11.006>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- DANE. (2024). Pobreza multidimensional en Colombia: Informe de resultados 2023. Departamento Administrativo Nacional de Estadística. <https://www.dane.gov.co>
- Departamento Nacional de Planeación. (2022). Focalización del gasto social en Colombia: evaluación del SISBEN IV. DNP.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232. <https://doi.org/10.1214/aos/1013203451>
- Lundberg, S., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30. <https://arxiv.org/abs/1705.07874>

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Universidad de los Andes. (2017). Encuesta Longitudinal Colombiana (ELCA): documentación técnica. CEDE. <https://datoscede.uniandes.edu.co>